DAGASVM: naprzemienna optymalizacja T′ ↔ V′ i dobór podzbioru walidacyjnego V′

Badanie uzupełniające followup_phase_switch (wersja v2) — ewolucyjny a losowy dobór V′, rozmiar V′, przełączanie faz, koszt

1. Streszczenie

Co zmieniono i dlaczego. Poprzednia wersja DAGASVM rozszerzała V′ w rytmie wyznaczanym przez wzrost K i sygnał ρ_{SV} (przyrost = K_{next} − K), a osiągnięcie BA(V′) = 1,0 kończyło przebieg albo — po zmianie reguły — wymuszało minimalny rozmiar V′ i ponowne sprawdzenie. W efekcie V′ rosło na Szachownicy średnio do 3 528 próbek. Zgodnie z uwagami promotora wprowadzono jawny automat dwóch faz: optymalizacji T′ (GA przy stałym K, ocena na całym skumulowanym V′) i optymalizacji V′ (dobór nowych próbek ΔV′ z puli V \ V′ przy ustalonym modelu). BA(V′) = 1,0 przełącza do fazy V′ i nie kończy algorytmu; rozmiar V′ ma jawne limity; koniec następuje po braku postępu.

Co wykonano. 690 przebiegów głównych (7 zbiorów, 3 warianty doboru V′: ewolucja, losowanie z harmonogramem ewolucji i losowanie z własnym automatem; podział bazowy: 20 seedów, trzy podziały dodatkowe: 5 seedów) oraz 21 przebiegów pilotażowych; wszystkie ukończone, bez błędów.

Co wykazano. (1) Implementacja spełnia 11 z 12 wymagań z uwag promotora w pełni lub z zastrzeżeniem, a jedno (najpierw zwiększać K) częściowo: w 144 przypadkach faza V′ zaczyna się z powodu bramki ρ_{SV} bez zwiększenia K. (2) V′ przestało rosnąć do nadmiernych rozmiarów: Szachownica 498 ± 121 próbek (1,8% V) wobec 3 528 (12,7%), przy BA na teście bez różnicy (0,0000); maks. |V′|/|V| w całej serii = 0,236. (3) Ewolucja wybiera istotnie trudniejsze próbki (błąd modelu na ΔV′ wyższy o 0,11–0,24 na wszystkich 7 zbiorach), ale **nie wykazano praktycznie istotnej przewagi jakościowej ewolucji nad losowaniem**: różnice BA na teście mieszczą się w [−0,21; 0,31] p.p., CI wyklucza zero tylko na Szachownicy (+0,31 p.p., poniżej przyjętej granicy 0,5 p.p.). (4) Ewolucja kosztuje więcej: 1,08–1,36× treningów SVM i 1,12–1,93× wierszy predict niż losowanie przy tym samym harmonogramie.

Najważniejszy problem, który pozostał. Rozmiar V′ i moment zakończenia wynikają głównie z reguł automatu (długość fazy V′ ≈ 3 rozszerzenia, liczba zastojów T′, bramka ρ_{SV}), a nie z sygnału jakościowego: w wariancie ewolucyjnym tylko 17% wejść do fazy V′ pochodzi z BA(V′) = 1, a 90% takich przypadków to V′ startowe (20 próbek). Trudność ΔV′ nie rośnie z kolejnymi rozszerzeniami, więc warunek „jakość nowych próbek przestała się pogarszać” jest spełniany niemal od razu i działa jak stała długość fazy.

2. Cel badania i pytania badawcze

Celem jest sprawdzenie, czy przebudowany algorytm DAGASVM — z naprzemienną optymalizacją podzbioru treningowego T′ i podzbioru walidacyjnego V′ — realizuje założenia promotora oraz czy ewolucyjny dobór V′ daje korzyść względem doboru losowego. Raport opisuje wyłącznie wykonane eksperymenty. Trudniejsze V′ i lepszy model są osobnymi właściwościami i są analizowane oddzielnie.

- **P0.** Czy implementacja spełnia 12 wymagań z uwag promotora (sekcja 5.1)?
- **P1.** Czy ewolucja wybiera trudniejsze próbki do ΔV′ niż losowanie (sekcja 5.3)?
- **P2.** Czy ewolucyjny dobór V′ prowadzi do lepszego modelu niż losowy, przy tym samym rozmiarze V′ (sekcja 5.4)?
- **P3.** Czy ewolucja jest warta dodatkowego kosztu obliczeniowego (sekcja 5.5)?
- **P4.** Czy V′ przestało rosnąć do nadmiernych rozmiarów i czy rozmiar V′ wpływa na jakość (sekcja 5.2)?
- **P5.** Jak działają warunki przełączania faz i zakończenia (sekcje 6 i 7)?

3. Opis algorytmu

Oznaczenia: V — pełny zbiór walidacyjny; V′ ⊂ V — skumulowany podzbiór walidacyjny sterujący algorytmem; ΔV′ — przyrost dodany w bieżącym rozszerzeniu (V′ ← V′ ∪ ΔV′); T′ — podzbiór treningowy (K próbek na klasę wybranych z pełnego zbioru treningowego); K — liczba próbek na klasę w T′; ρ_{SV} — udział wektorów podpierających w T′ po treningu SVM; TSV — próg ρ_{SV} (0,25). Jeden *cykl* to jeden krok automatu: jedno uruchomienie GA dla T′ albo jedno rozszerzenie V′.

3.1 Faza optimize_T_prime

GA (populacja 30, do 30 generacji) wybiera T′ o zadanym K z pełnego zbioru treningowego; fitness osobnika = metryka (domyślnie balanced accuracy) SVM wytrenowanego na T′, policzona na całym skumulowanym V′. Kolejna optymalizacja startuje z poprzednim najlepszym T′ w populacji (warm start), więc wynik przy tym samym K nie pogarsza się. GA kończy się wcześnie po 3 generacjach bez poprawy o ≥ 0,0005 albo po osiągnięciu BA(V′) = 1,0. Po GA liczone są: BA(V′) najlepszego T′, ρ_{SV} i kandydat na kolejne K.

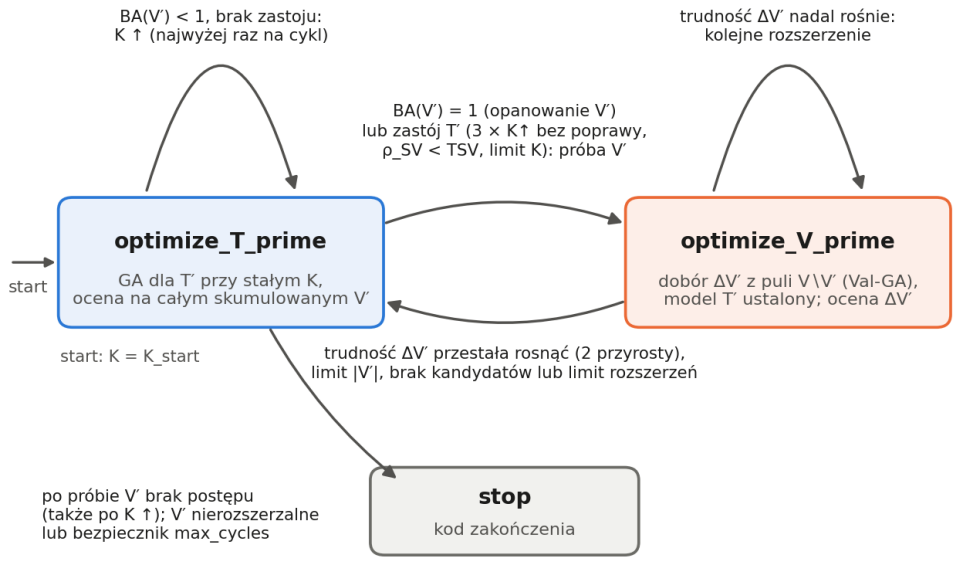
3.2 Faza optimize_V_prime

Model T′ jest ustalony na czas fazy. Dobór ΔV′ odbywa się wyłącznie z puli kandydatów V \ V′ (stare próbki V′ nie są oceniane ponownie). Wariant ewolucyjny: adwersarialny GA (Val-GA, populacja 30, 20 generacji) szuka zbioru 10 próbek na klasę (łącznie 10·liczba klas), na którym ustalony model radzi sobie najgorzej; fitness osobnika Val-GA = 1 − BA modelu na wybranym podzbiorze ΔV′. Wariant losowy: ΔV′ losowane z puli. Po rozszerzeniu mierzone są: BA i błąd klasyfikacji na ΔV′, skład klasowy ΔV′, zmiana trudności względem poprzedniego przyrostu oraz koszt. Trudność przyrostu to odsetek błędów modelu na ΔV′. Faza trwa, dopóki trudność (średnia z 2 ostatnich przyrostów) rośnie o co najmniej 0,01; po 2 kolejnych przyrostach bez takiego wzrostu faza się kończy.

3.3 Przełączanie faz

Tabela 1. Maszyna fazowa — warunki przejść zgodne z kodem automatu. Do żadnego warunku nie wchodzą pełne V ani test.

Aktualna faza	Warunek	Działanie	Następna faza
optimize_T_prime	BA(V′) = 1,0 i V′ można rozszerzyć	K bez zmian; zapamiętanie modelu (opanowanie V′)	optimize_V_prime
optimize_T_prime	BA(V′) = 1,0, a V′ nierozszerzalne (limit rozmiaru, limit rozszerzeń lub brak kandydatów)	zakończenie algorytmu	stop (stop_perfect_on_max_vprime)
optimize_T_prime	BA(V′) < 1,0; brak zastoju (< 3 kolejnych zwiększeń K bez poprawy o ≥ 0,0005); ρ_{SV} ≥ TSV; K może rosnąć	K ← K_{next} (wzór DAGA zależny od ρ_{SV}); najwyżej raz w cyklu; ponowne GA	optimize_T_prime
optimize_T_prime	BA(V′) < 1,0 i zastój: 3 kolejne zwiększenia K bez poprawy, albo ρ_{SV} < TSV, albo limit K klasy; próba V′ przy tym K jeszcze nie wykonana; V′ rozszerzalne	zapamiętanie najlepszego T′ i jego fitnessu jako poziomu odniesienia (próba V′)	optimize_V_prime
optimize_T_prime	j.w., ale próba przy tym K już była, V′ nierozszerzalne albo próby wyłączone	zakończenie algorytmu	stop (stop_tprime_no_progress, stop_no_k_growth_signal lub stop_k_limit)
optimize_T_prime (po próbie V′)	T′ nie osiągnęło poziomu odniesienia (fitness < najlepszy T′ sprzed próby, oceniony na tym samym V′, + 0,0005); K może rosnąć; < 3 kolejnych niepowodzeń	K ← K_{next} (raz), ponowna optymalizacja T′	optimize_T_prime
optimize_T_prime (po próbie V′)	j.w., ale K nie może rosnąć (ρ_{SV} < TSV albo limit klasy) lub 3 zwiększenia K nie dały poziomu	zakończenie algorytmu	stop (stop_no_progress_after_vprime_retry)
optimize_T_prime (po próbie V′)	poziom odniesienia osiągnięty (albo BA(V′) = 1)	powrót do zwykłej pracy; licznik zastoju od zera	optimize_T_prime lub optimize_V_prime
optimize_V_prime	trudność ΔV′ (średnia z okna 2) wzrosła o ≥ 0,01	kolejne rozszerzenie V′ (+10 próbek/klasę)	optimize_V_prime
optimize_V_prime	2 kolejne przyrosty bez wzrostu trudności; albo limit |V′| (≤ 0,25·|V|); albo brak kandydatów; albo 10 rozszerzeń w fazie	koniec fazy; T′ optymalizowane na pełnym, skumulowanym V′ przy tym samym K	optimize_T_prime



Pełne V i test nie uczestniczą w żadnym przejściu — tylko obserwacja po decyzji.

Rys. 1. Diagram maszyny fazowej. Pętla przy optimize_T_prime = zwiększenie K; pętla przy optimize_V_prime = kolejne rozszerzenie V′.

3.4 Role K, ρ_{SV}, TSV i Ts

Tabela 2. Znaczenie parametrów K, ρ_{SV}, TSV i Ts. Uwaga: wzór na K_{next} zawiera wartość bezwzględną, więc poniżej TSV działałby odwrotnie (im niższe ρ_{SV}, tym większy krok) — dlatego włączona jest bramka $\rho_{SV} \geq$ TSV.

Parametr	Rola w tym algorytmie	Czego nie robi
K	rozmiar T′ (próbek na klasę); rośnie tylko w fazie T′, najwyżej raz na cykl, nigdy przy BA(V′) = 1	nie wpływa na przyrost V′
ρ_{SV}	(i) wielkość kroku K: K_{next} = ceil(K·(1 + |ρ_{SV} − TSV| / (1 − TSV))), co najmniej K + 1; (ii) bramka: przy ρ_{SV} < TSV K nie rośnie, a taki krok jest zastojem T′ (próba V′)	sam nie rozszerza V′
TSV = 0,25	próg dla ρ_{SV}	nie może samodzielnie powodować wzrostu V′
Ts = 3	cierpliwość wewnątrz GA dla T′ (generacje bez poprawy o ≥ 0,0005)	nie steruje fazami ani rozmiarem V′

3.5 Warunek zakończenia

Algorytm kończy się: (a) po nieudanej próbie V′ — gdy T′ nie osiąga poziomu odniesienia także po zwiększeniach K (*stop_no_progress_after_vprime_retry*), (b) przy zastoju T′, gdy próba V′ przy tym K już była lub V′ nie da się rozszerzyć (*stop_tprime_no_progress*, *stop_no_k_growth_signal*, *stop_k_limit*), (c) gdy BA(V′) = 1, a V′ nierozszerzalne (*stop_perfect_on_max_vprime*), (d) bezpiecznikiem 300 cykli. Dodatkowe zabezpieczenia przed zapętleniem: najwyżej jedna próba V′ na poziom K, rosnące K, ograniczony rozmiar V′. BA(V′) = 1,0 podczas optymalizacji T′ nigdy samo nie kończy algorytmu.

3.6 Funkcja fitness: co jest używane i gdzie

Tabela 3. Użycie metryk w algorytmie. Kary: class_imbalance_penalty = 0; brak kary za rozmiar T′ ani V′.

Miejsce	Metryka (konfiguracja)	Na czym liczona	Steruje?
fitness osobników GA dla T′	balanced accuracy (fitness.tprime_metric)	cały skumulowany V′	tak (selekcja, zatrzymanie GA przy BA = 1)
wartość kroku T′ (opanowanie, poprawa, zastój, postęp po próbie V′)	balanced accuracy	V′	tak
fitness osobników Val-GA (wybór ΔV′)	1 − balanced accuracy (fitness.vprime_metric)	wyłącznie podzbiór ΔV′ z puli V \ V′	tak (wariant ewolucyjny)
trudność ΔV′ (koniec fazy V′)	odsetek błędów = 1 − accuracy (vprime_difficulty_metric)	ΔV′	tak
wybór modelu reprezentatywnego	balanced accuracy	końcowy V′	tak (po zakończeniu)
BA/F1/accuracy na pełnym V i na teście	te same metryki	pełne V, test	nie — wyłącznie obserwacja po decyzji

Konsekwencje. BA(V′) = 1,0 oznacza zero błędów na V′ (każda klasa jest obecna w V′ od startu), więc BA, accuracy i F1-macro mają ten sam próg „opanowania”; dla AUC tak nie byłoby, bo AUC = 1 nie oznacza zera błędów przy progu decyzyjnym SVM, i przy badaniu metryk próg trzeba definiować osobno. V′ jest budowane przeciw bieżącemu T′, a T′ jest optymalizowane na V′, więc BA(V′) nie jest nieobciążoną oceną uogólniania (dlatego test i pełne V są tylko obserwacją). **F1 i AUC nie były używane jako fitness**. W zapisanych wynikach pola roc_auc i pr_auc są równe BA, bo SVM jest trenowany z probability = false; **AUC nie został policzony** i raport go nie podaje. F1-macro i accuracy na teście zostały policzone dla modelu reprezentatywnego i są raportowane jako obserwacje. Porównanie BA z F1 i AUC jako fitnessem pozostaje do wykonania (wymaga probability = true i rozszerzenia Val-GA, który obsługuje dziś tylko BA, accuracy i binarne F1).

4. Konfiguracja eksperymentu

4.1 Kompletność i status przebiegów

Tabela 4. Kompletność serii (stan wg plików statusów jobów i wyjść kolejek). Wszystkie joby mają status completed; 0 jobów failed lub running, 0 kodów wyjścia ≠ 0, 0 wpisów Traceback/ERROR w logach.

Seria	Rola	Podział	Zbiory × warianty × seedy	Zaplan.	Ukończone	Błędy
v2_full	główna	2026	7 × 3 × 20	420	420	0
v2_smoke_chess_r1000	pilotaż	2026	1 × 3 × 2	6	6	0
v2_smoke_chess_r1000_nogate	pilotaż	2026	1 × 3 × 2	6	6	0
v2_smoke_moons	pilotaż	2026	1 × 3 × 3	9	9	0
v2_split2027	główna	2027	6 × 3 × 5	90	90	0
v2_split2028	główna	2028	6 × 3 × 5	90	90	0
v2_split2029	główna	2029	6 × 3 × 5	90	90	0
10 serii bez prefiksu v2_	wcześniejsza wersja automatu (v1) — poza wnioskami	2026	smoke i krótkie serie	111	111	0
Razem główne				**690**	**690**	**0**

Do wniosków wykorzystano **690 przebiegów** (420 + 3·90): podział bazowy 2026 (7 zbiorów × 3 warianty × 20 seedów: 42–61) i podziały 2027–2029 (6 zbiorów zależnych od podziału × 3 warianty × 5 seedów: 42–46). Szachownica czyta stały plik, więc ma tylko podział bazowy. Pilotaż (21 przebiegów: Moons 3 seedy, Szachownica 2 seedy, limit |V′| = 1000, w tym wariant bez bramki ρ_{SV}) jest oznaczony jako pilotażowy i nie wchodzi do głównych wniosków. 111 przebiegów wcześniejszej wersji automatu (v1) pochodzi z innej semantyki próby V′ i nie jest używane; jedna seria pilotażowa zawiera jeden zdublowany przebieg (identyczny co do wyniku; agregacja bierze najnowszy). Liczba cykli (kroków automatu) w danych głównych: 27 671.

4.2 Zbiory danych, podziały i seedy

Tabela 5. Zbiory (rozmiary zbiorów treningowego, walidacyjnego i testowego są takie same na wszystkich podziałach; Digits: 10 klas, MAGIC: podpróbka 8000 obserwacji). Hiperparametry SVM (jądro RBF, class_weight = balanced) są wspólne dla wszystkich podziałów.

Zbiór	Klasy / cechy	Trening	V (pełne)	Test	K_{start}	C	γ
Szachownica	2 / 2	19 949	27 853	22 169	10	10	0,002
Moons	2 / 2	4 800	4 800	2 400	10	1	2,000
Circles	2 / 2	4 800	4 800	2 400	10	10	0,100
Spiral	2 / 2	4 800	4 800	2 400	10	1000	4,000
Classification 2D	2 / 2	4 800	4 800	2 400	10	1	1,000
Digits	10 / 64	718	719	360	5	100	0,002
MAGIC	2 / 10	3 200	3 200	1 600	10	10	0,050

Podział bazowy 2026 pochodzi z poprzedniego badania V′; podziały 2027–2029 zmieniają wyłącznie przydział obserwacji do zbiorów (pula obserwacji i generatory są stałe). Hiperparametry (C, γ) wybrano raz w poprzednim badaniu i użyto wszędzie; część V podziału bazowego trafia na podziałach dodatkowych do zbioru testowego, co daje niewielki, wspólny dla wariantów optymizm poziomów bezwzględnych i nie wpływa na porównania wariantów.

4.3 Parametry GA i automatu

Tabela 6. Parametry. Wartości robocze, nie strojone; wrażliwość na nie nie była badana.

Grupa	Parametry (wartości domyślne użyte we wszystkich seriach głównych)
GA dla T′	populacja 30, ≤ 30 generacji, turniej 3, krzyżowanie 0,8, mutacja 0,05, elitaryzm 2; wczesne zatrzymanie: Ts = 3 generacje bez poprawy o ≥ 0,0005 lub BA(V′) = 1; warm start
Val-GA (dobór ΔV′)	populacja 30, ≤ 20 generacji, turniej 3, krzyżowanie 0,8, mutacja 0,1, elitaryzm 2
V′ i przyrosty	V′ startowe: K_{start} próbek na klasę (losowe, zrównoważone); przyrost 10 próbek/klasę; limit |V′| ≤ 0,25·|V|; limit rozszerzeń globalny: brak; w fazie: 10
Faza V′	trudność = odsetek błędów na ΔV′; okno 2; min. wzrost 0,01; cierpliwość 2
Zastój i stop	3 kolejne zwiększenia K bez poprawy o ≥ 0,0005; jedna próba V′ na poziom K; po próbie: ponowne zwiększenia K, poziom odniesienia = najlepszy T′ sprzed próby na tym samym V′; bezpiecznik 300 cykli
K i ρ_{SV}	TSV = 0,25; bramka ρ_{SV} włączona (K rośnie tylko przy ρ_{SV} ≥ TSV); K ≤ liczność najmniejszej klasy treningowej
Model reprezentatywny	najlepszy T′ na końcowym V′ (wybór wyłącznie po V′)

4.4 Warianty

Tabela 7. Warianty. Główne porównanie ewolucja ↔ losowanie wykonano na rand_replay (identyczny rozmiar V′); rand_switch jest porównaniem pomocniczym. Wariant ze stałym rozmiarem V′ pochodzącym z wyniku ewolucji (rand_fixed) nie był używany.

Wariant	Dobór ΔV′	Harmonogram faz, K, |ΔV′| i moment stopu	Uwagi o porównywalności
evo_switch (ewolucja)	Val-GA (adwersarialny)	własny automat	wariant badany
rand_replay (losowanie, harmonogram z ewolucji)	losowy z puli V \ V′	odtworzony z przebiegu evo_switch o tym samym seedzie	to samo V′ startowe, ten sam |V′|, K i liczba cykli; **uprzywilejowany**: harmonogram (w tym K i stop) pochodzi z ewolucji, więc nie jest samodzielnym algorytmem
rand_switch (losowanie, własny automat)	losowy z puli V \ V′	własny automat z tymi samymi regułami	samodzielny algorytm, ale |V′| i K są inne niż w ewolucji (mniejsze), więc różnica miesza efekt doboru z efektem rozmiaru

5. Wyniki

5.1 Zgodność implementacji z uwagami promotora (P0)

Tabela 8. Weryfikacja 12 wymagań na 690 przebiegach i 27 671 cyklach (pełna tabela zapisana w katalogu tabel raportu). Wymagania 4, 5, 7, 11 mają dodatkowo testy jednostkowe z podsłuchem danych przekazywanych GA i z zatrutym obserwatorem pełnego V i etykietami testu.

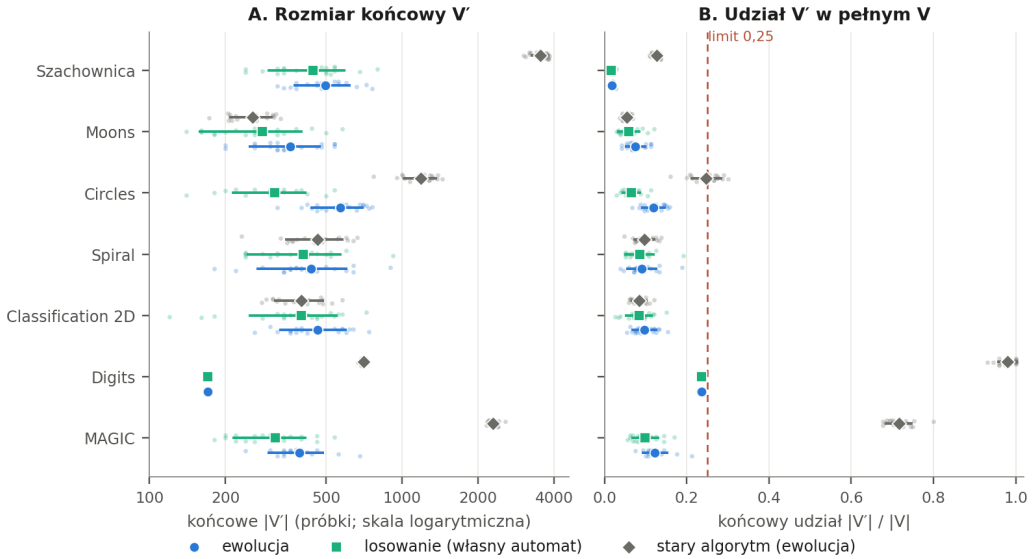
Nr	Wymaganie	Dowód w danych	Status
1	BA(V′)=1,0 w T′ nie kończy ewolucji	443 kroków T′ z BA(V′)=1 (wersje z własnym automatem): 440 → przełączenie do V′; 3 → stop, wyłącznie gdy V′ nie dało się już rozszerzyć (kod stop_perfect_on_max_vprime: digits); K wzrosło w 0 z 443 takich kroków.	SPEŁNIONE (z jednym ograniczeniem: stop, gdy V′ nierozszerzalne)
2	Po BA(V′)=1 przejście do rozszerzenia i optymalizacji V′	440 z 440 przełączeń kończy się cyklem w fazie optimize_V_prime.	SPEŁNIONE
3	Po rozszerzeniu V′ powrót do optymalizacji T′	2959 zakończeń fazy V′ (wszystkie warianty); następny cykl nie jest T′: 0.	SPEŁNIONE
4	Dobór V′: osobniki oceniane wyłącznie na nowych próbkach ΔV′, kandydaci = V\V′	W każdym kroku V′ ewolucji liczba wierszy przekazanych modelowi = |V\V′| + 2·|ΔV′|: 4334 z 4334 kroków (jedno predict na pulę kandydatów + diagnostyka ΔV′); stare próbki V′ nie są oceniane ponownie. Losowanie: 2·|ΔV′|, 7564 z 7564. Ograniczenie: cała pula V\V′ jest oceniana raz na rozszerzenie (zbuforowane predykcje), a nie tylko ΔV′.	SPEŁNIONE (z ograniczeniem kosztu puli)
5	T′ optymalizowane na całym, skumulowanym V′	Koszt oceny T′ = liczba ocen GA × |V′| aktualnego, skumulowanego V′: 15773 z 15773 kroków; |V′| nie maleje w żadnym z 690 przebiegów (690); ponadto test jednostkowy porównuje dane widziane przez GA z V′ ze stanu pamięci (test_req04).	SPEŁNIONE
6	Gdy BA(V′) < 1, najpierw zwiększane jest K	Z 9620 kroków T′ z BA(V′)<1: 7713 (80,2%) zwiększa K; 1450 przechodzi do V′ — z tego 1267 po 3 nieskutecznych zwiększeniach K, 144 z powodu bramki ρ_{SV} < TSV (bez zwiększenia K) i 39 z powodu limitu K klasy; 457 kończy przebieg.	SPEŁNIONE CZĘŚCIOWO (odstępstwo: bramka ρ_{SV})
7	K nie rośnie więcej niż raz w cyklu	Cykle ze zmianą K w fazie V′: 0; cykle, w których wzrosło K i jednocześnie rozszerzono V′: 0; w cyklu T′ uruchamiane jest jedno GA przy jednym K, a decyzja o wzroście K jest jedna (kontrola ciągłości: K następnego cyklu = K po poprzednim cyklu w 26981 z 26981 przejść).	SPEŁNIONE
8	Warunek zakończenia po braku postępu	stop_no_progress_after_vprime_retry kończy 260 z 690 przebiegów (78 z 230 przebiegów ewolucyjnych); dodatkowo stop_tprime_no_progress, stop_no_k_growth_signal, stop_k_limit. Przebiegi zakończone bezpiecznikiem max_cycles: 0.	SPEŁNIONE
9	V′ nie rośnie bez ograniczeń	Maks. |V′|/|V| w 690 przebiegach: 0,236 (limit 0,25); maks. |V′| na Szachownicy: 800 (stary algorytm: średnio ≈ 3528). Stan blokady rozszerzania na końcu przebiegu: brak blokady: 585, limit rozmiaru: 105; limit rozmiaru zablokował dalszy wzrost w 105 przebiegach (digits: 105), w pozostałych wzrost zatrzymały reguły automatu.	SPEŁNIONE
10	Raportowane |V′|, |V| i |V′|/|V|	Kolumny vprime_rows, full_validation_rows, vprime_fraction wypełnione w 100% przebiegów i w każdym cyklu; niezgodność |V′|/|V|: 0.	SPEŁNIONE
11	Pełne V i test nie sterują algorytmem	Flagi used_full_validation_for_control / used_test_for_control w summary.json: wartość „prawda” w 0 z 1380; testy jednostkowe: trajektorie identyczne przy obserwatorze pełnego V zwracającym losowe wartości i przy odwróconych etykietach testu (test_req10).	SPEŁNIONE
12	Wariant losowy porównywany z ewolucyjnym przy porównywalnym |V′|	rand_replay: identyczny końcowy |V′| w 230 z 230 par (harmonogram faz, K i |ΔV′| odtworzony z przebiegu ewolucyjnego). rand_switch (własny automat): mediana stosunku |V′| do ewolucji = 0,86. Uprzywilejowanie: harmonogram (w tym K i moment stopu) rand_replay pochodzi z ewolucji, więc wariant ten nie jest samodzielnym algorytmem.	SPEŁNIONE (z zastrzeżeniem uprzywilejowania rand_replay)

Różnice względem założeń (szczegóły w sekcji 8): (a) wymaganie 6 spełnione częściowo — bramka ρ_{SV} powoduje, że przy ρ_{SV} < TSV algorytm przechodzi do V′ bez zwiększania K; (b) wymaganie 1 — BA(V′) = 1 kończy algorytm tylko wtedy, gdy V′ nie da się już rozszerzyć (3 przypadki, Digits); (c) wymaganie 4 — ocena odbywa się na ΔV′, ale cała pula V \ V′ jest oceniana raz na rozszerzenie; (d) wymaganie 12 — wariant rand_replay jest uprzywilejowany harmonogramem ewolucji.

5.2 Rozmiar V′ (P4)

Tabela 9. Końcowy rozmiar V′ (podział 2026, 20 seedów). Stary algorytm: evo_mem z badania followup_stop_rule, te same seedy i podział; kolumna „rozszerzenia" oznacza liczbę kroków rozszerzenia. Średni przyrost ΔV′ = 20 próbek (10/klasę × 2 klasy) wszędzie poza Digits (limit rozmiaru ogranicza ostatni przyrost: 100 + 20 próbek).

Zbiór	Wariant	n	|V′| śr.	mediana	SD	|V| śr.	|V′|/|V|	rozszerzenia V′	przyrost ΔV′
Szachownica	ewolucja	20	498	480	121	27 853	0,018	23,9	20
	los. (harm. ewol.)	20	498	480	121	27 853	0,018	23,9	20
	los. (własny)	20	443	470	146	27 853	0,016	21,1	20
	stary algorytm	20	3528	3606	266	27 853	0,127	44,4	—
Moons	ewolucja	20	361	330	110	4 800	0,075	17,1	20
	los. (harm. ewol.)	20	361	330	110	4 800	0,075	17,1	20
	los. (własny)	20	279	260	121	4 800	0,058	12,9	20
	stary algorytm	20	256	264	47	4 800	0,053	14,6	—
Circles	ewolucja	20	568	580	129	4 800	0,118	27,4	20
	los. (harm. ewol.)	20	568	580	129	4 800	0,118	27,4	20
	los. (własny)	20	314	300	100	4 800	0,065	14,7	20
	stary algorytm	20	1188	1211	172	4 800	0,247	38,4	—
Spiral	ewolucja	20	435	390	166	4 800	0,091	20,8	20
	los. (harm. ewol.)	20	435	390	166	4 800	0,091	20,8	20
	los. (własny)	20	407	400	161	4 800	0,085	19,4	20
	stary algorytm	20	463	465	115	4 800	0,097	22,6	—
Classification 2D	ewolucja	20	464	410	133	4 800	0,097	22,2	20
	los. (harm. ewol.)	20	464	410	133	4 800	0,097	22,2	20
	los. (własny)	20	400	400	150	4 800	0,083	19,0	20
	stary algorytm	20	400	403	84	4 800	0,083	17,8	—
Digits	ewolucja	20	170	170	0	719	0,236	2,0	60
	los. (harm. ewol.)	20	170	170	0	719	0,236	2,0	60
	los. (własny)	20	170	170	0	719	0,236	2,0	60
	stary algorytm	20	705	705	16	719	0,980	5,0	—
MAGIC	ewolucja	20	392	370	95	3 200	0,123	18,6	20
	los. (harm. ewol.)	20	392	370	95	3 200	0,123	18,6	20
	los. (własny)	20	315	310	99	3 200	0,098	14,8	20
	stary algorytm	20	2290	2253	100	3 200	0,716	15,2	—



punkt = średnia, odcinek = ±1 SD, drobne punkty = pojedyncze przebiegi (podział 2026, 20 seedów). Losowanie z harmonogramem ewolucji ma z konstrukcji ten sam |V′| co ewolucja.

Rys. 2. Końcowy |V′| (A, skala logarytmiczna) i udział |V′|/|V| (B) w podziale 2026. Losowanie z harmonogramem ewolucji ma z konstrukcji ten sam |V′| co ewolucja.

Czy nowa metoda ograniczyła wzrost V′? Tak, tam, gdzie stary algorytm go nie ograniczał: Szachownica 3 528 → 498 (mediana 480, 7,1× mniej), MAGIC 2 290 → 392, Digits 705 → 170, Circles 1 188 → 568. Na Moons i Classification 2D nowe V′ **nie** jest mniejsze (256 → 361 i 400 → 464), na Spiral porównywalne. Maksymalny udział |V′|/|V| w całej serii wynosi 0,236, maks. |V′| na Szachownicy 800.

Powód zakończenia wzrostu V′. V′ przestaje rosnąć razem z końcem przebiegu. Limit rozmiaru (0,25·|V|) zablokował dalszy wzrost wyłącznie na Digits (105 z 690 przebiegów; |V′| = 170 z 719, ostatni przyrost 100 próbek nie mieści się w limicie 179), w pozostałych przebiegach wzrost zatrzymały reguły automatu (sekcja 6). Ograniczenie wzrostu wynika więc z reguł fazy V′ i liczby zastojów T′, a nie z limitu rozmiaru.

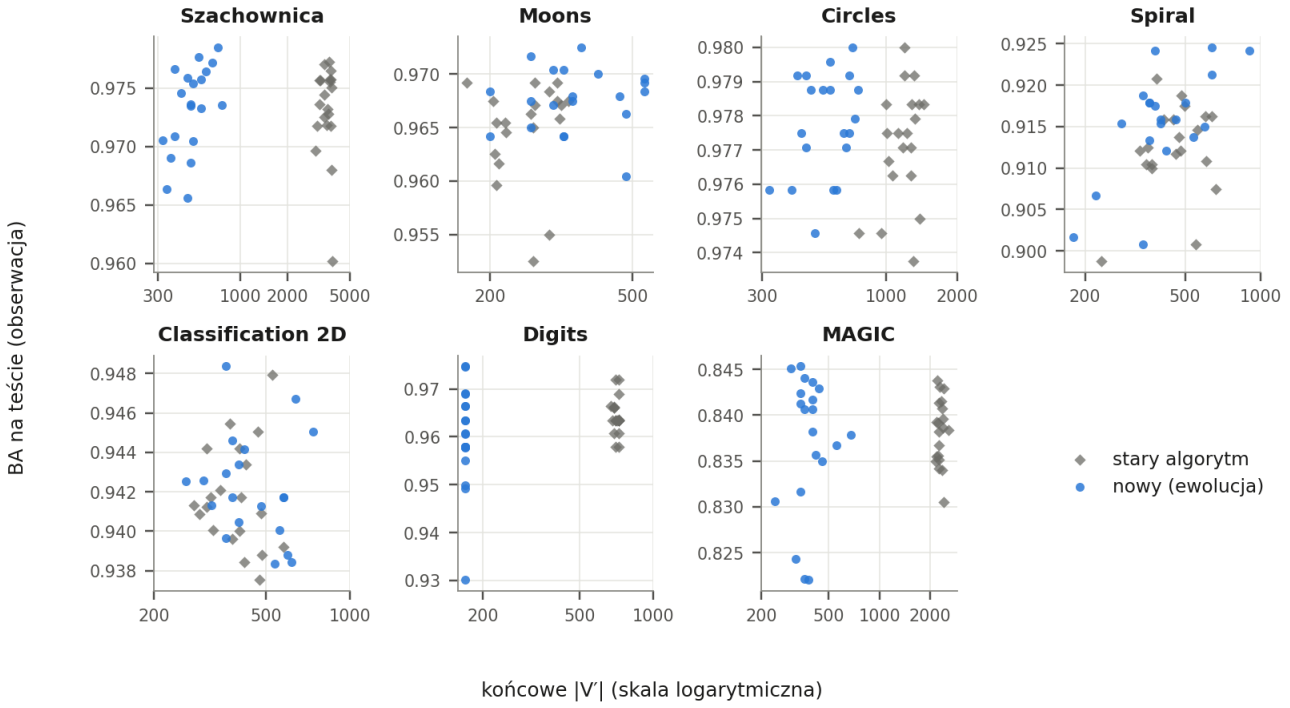
Czy V′ rośnie do rozmiaru, przy którym losowanie jest wystarczające? Przy rozmiarach uzyskanych w tym badaniu losowanie z identycznym harmonogramem daje ten sam wynik testowy co ewolucja (sekcja 5.4). Nie badano jednak stałej siatki mniejszych rozmiarów V′, więc nie wiadomo, od jakiego rozmiaru losowanie przestaje wystarczać ani czy przy mniejszych V′ ewolucja pomaga bardziej.

Czy dla Szachownicy udało się porównanie przy ≈ 1000 próbek? W serii głównej (wartości domyślne) końcowe |V′| wynosi 498 (maks. 800) — nie 1000 i nie ≈ 3500. Rozmiar bliski 1000 uzyskano tylko w pilotażu (limit |V′| = 1000, bez bramki ρ_{SV}, n = 2 seedy): |V′| = 870 (740–1 000), BA test ewolucji 0,9868 i losowania z harmonogramem 0,9867. Przy n = 2 jest to wyłącznie ilustracja, że porównanie przy takim rozmiarze jest wykonalne; nie jest podstawą wniosków. W tym pilotażu K rośnie do ≈ 5500 (bramka wyłączona), więc zmiana |V′| jest zmieszana ze zmianą K.

5.2.1 Czy rozmiar V′ wpływa na jakość modelu?

Tabela 10. Rozmiar V′ a BA na teście. Kolumny 2–6: korelacje rang w obrębie zbioru, wariant ewolucyjny, podział 2026 (n = 20; ρ cząstkowa po usunięciu wpływu K; p bez korekty na wielokrotność). Kolumny 7–10: stary algorytm (evo_mem) a nowy, te same seedy (różnica sparowana, bootstrap). Dla Digits i MAGIC K jest stałe (limit klasy), więc ρ cząstkowa jest niezdefiniowana.

Zbiór	ρ |V′|–BA test	p	ρ K–BA test	ρ cząstkowa |V′|–BA | K	p	|V′| nowy / stary	BA test nowy − stary	95% CI	nie gorsze o > 0,5 p.p.
Szachownica	0,54	0,015	0,23	0,51	0,023	498 / 3 528	0,0000	[−0,0025; 0,0027]	tak
Moons	0,14	0,558	0,45	−0,10	0,664	361 / 256	0,0028	[0,0001; 0,0058]	tak
Circles	0,24	0,308	−0,08	0,31	0,185	568 / 1 188	0,0006	[−0,0004; 0,0015]	tak
Spiral	0,48	0,032	0,46	0,25	0,289	435 / 463	0,0032	[−0,0004; 0,0069]	tak
Classification 2D	−0,14	0,568	−0,22	−0,01	0,968	464 / 400	0,0005	[−0,0012; 0,0022]	tak
Digits	—	—	—	—	—	170 / 705	−0,0043	[−0,0100; 0,0004]	nie
MAGIC	−0,05	0,823	—	—	—	392 / 2 290	−0,0011	[−0,0039; 0,0017]	tak



Rys. 3. BA na teście (obserwacja) w zależności od końcowego |V′|: wariant ewolucyjny nowego algorytmu (niebieski) i stary algorytm (szary), podział 2026, 20 seedów.

Wniosek. Między algorytmami: 4–7× mniejsze V′ (Szachownica, MAGIC, Digits) nie dało mierzalnego spadku jakości na Szachownicy i MAGIC (dolna granica CI różnicy > −0,5 p.p.); na Digits (różnica −0,0043, CI [−0,0100; 0,0004]) nie można

wykluczyć spadku większego niż 0,5 p.p. Większe V′ starego algorytmu nie dało więc poprawy na tych zbiorach. To porównanie jest opisowe, bo algorytmy różnią się także polityką K i przełączaniem faz. W obrębie nowego algorytmu dodatnia korelacja |V′|–BA widoczna na Szachownicy (ρ cząstkowa po kontroli K: 0,51) i na Spiral (przed kontrolą K) nie ma charakteru przyczynowego: |V′| i K rosną razem z długością przebiegu, a przebiegi o różnej długości kończą się z różnych powodów. Na pozostałych zbiorach korelacji nie ma.

5.3 Czy ewolucja wybiera trudniejsze próbki? (P1)

Tabela 11. Trudność przyrostów ΔV′ (średnia z kroków V′ w przebiegu; podział 2026, n = 20 par po seedach; losowanie z harmonogramem ewolucji). Ewolucja wybiera próbki, na których ustalony model myli się wyraźnie częściej; BA(ΔV′) jest o 0,17–0,36 niższe.

Zbiór	błąd na ΔV′ — ewolucja	błąd na ΔV′ — losowanie	różnica	95% CI	d_z	p (Holm)	BA na ΔV′ ewol.	BA na ΔV′ los.
Szachownica	0,280 ± 0,044	0,098 ± 0,028	0,182	[0,172; 0,193]	7,3	<0,001	0,672	0,904
Moons	0,211 ± 0,019	0,048 ± 0,014	0,163	[0,156; 0,170]	9,7	<0,001	0,753	0,953
Circles	0,171 ± 0,018	0,033 ± 0,013	0,137	[0,131; 0,143]	9,9	<0,001	0,794	0,967
Spiral	0,371 ± 0,042	0,132 ± 0,031	0,239	[0,227; 0,251]	8,3	<0,001	0,593	0,870
Classification 2D	0,270 ± 0,022	0,074 ± 0,018	0,196	[0,187; 0,205]	9,6	<0,001	0,690	0,926
Digits	0,198 ± 0,049	0,084 ± 0,051	0,115	[0,101; 0,128]	3,6	<0,001	0,738	0,921
MAGIC	0,370 ± 0,041	0,181 ± 0,020	0,189	[0,172; 0,207]	4,5	<0,001	0,440	0,804

Tak. Różnica błędu na ΔV′ wynosi od 0,115 do 0,239 na wszystkich 7 zbiorach (CI wyklucza zero, p Holma < 0,001, d_z od 3,6 do 9,9), a BA na ΔV′ jest niższe o 0,17–0,36. Rozmiar efektu jest bardzo duży, wynik robustny (te same seedy, ten sam harmonogram). Zastrzeżenie: modele T′ w obu wariantach nie są identyczne (różne V′), więc trudność jest mierzona względem modelu danego wariantu. **To stwierdzenie dotyczy wyłącznie trudności próbek, nie jakości modelu** (sekcja 5.4).

5.4 Czy ewolucja prowadzi do lepszego modelu? (P2)

Tabela 12. BA na teście, ewolucja − losowanie z harmonogramem ewolucji (podział 2026, n = 20 par po seedach; 95% CI z bootstrapu; p Holma z testu Wilcoxona, 7 zbiorów). Test jest wyłącznie obserwacją. Granica 0,5 p.p. jest przyjętą konwencją, nie wynikiem z danych.

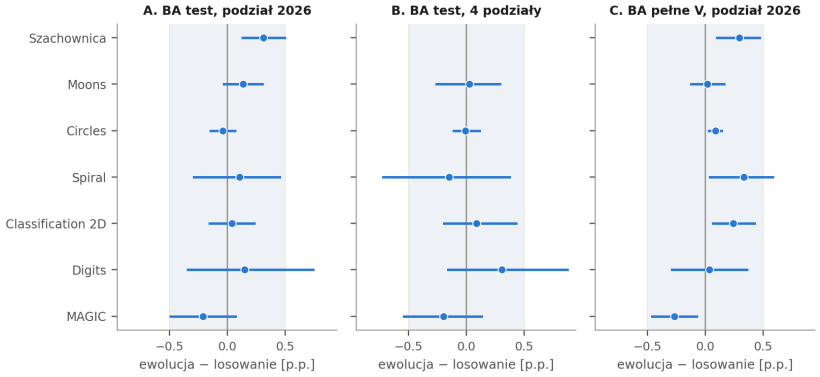
Zbiór	ewolucja (śr. ± SD)	losowanie (śr. ± SD)	różnica	95% CI	d_z	p (Holm)	ocena praktyczna (granica 0,5 p.p.)
Szachownica	0,9732 ± 0,0038	0,9700 ± 0,0033	0,0031	[0,0013; 0,0050]	0,74	0,045	praktycznie zaniedbywalna
Moons	0,9676 ± 0,0030	0,9663 ± 0,0027	0,0014	[−0,0003; 0,0030]	0,34	0,763	praktycznie zaniedbywalna
Circles	0,9777 ± 0,0015	0,9781 ± 0,0017	−0,0004	[−0,0015; 0,0006]	−0,16	1,000	praktycznie zaniedbywalna
Spiral	0,9155 ± 0,0065	0,9145 ± 0,0066	0,0010	[−0,0029; 0,0045]	0,12	1,000	praktycznie zaniedbywalna
Classification 2D	0,9422 ± 0,0027	0,9418 ± 0,0035	0,0004	[−0,0015; 0,0023]	0,09	1,000	praktycznie zaniedbywalna
Digits	0,9600 ± 0,0099	0,9585 ± 0,0109	0,0015	[−0,0034; 0,0074]	0,12	1,000	nierozstrzygnięta
MAGIC	0,8371 ± 0,0074	0,8392 ± 0,0037	−0,0021	[−0,0049; 0,0007]	−0,32	1,000	praktycznie zaniedbywalna

Tabela 13. Metryki dodatkowe (obserwacje): F1-macro na teście i BA na pełnym V, ewolucja − losowanie (podział 2026, n = 20). AUC nie został policzony (patrz sekcja 3.6).

Zbiór	F1-macro test: ewol.	F1-macro: los.	różnica [95% CI]	p (Holm)	BA pełne V: różnica [95% CI]	p (Holm)
Szachownica	0,9733	0,9703	0,0030 [0,0012; 0,0049]	0,095	0,0029 [0,0010; 0,0047]	0,066
Moons	0,9676	0,9663	0,0014 [−0,0003; 0,0031]	0,947	0,0002 [−0,0012; 0,0016]	1,000
Circles	0,9777	0,9781	−0,0004 [−0,0014; 0,0007]	1,000	0,0009 [0,0003; 0,0014]	0,074
Spiral	0,9155	0,9144	0,0010 [−0,0029; 0,0045]	1,000	0,0034 [0,0004; 0,0058]	0,074
Classification 2D	0,9421	0,9417	0,0004 [−0,0015; 0,0023]	1,000	0,0024 [0,0007; 0,0042]	0,074
Digits	0,9602	0,9588	0,0014 [−0,0033; 0,0076]	1,000	0,0003 [−0,0029; 0,0036]	1,000
MAGIC	0,8346	0,8391	−0,0045 [−0,0078; −0,0013]	0,264	−0,0027 [−0,0046; −0,0008]	0,074

Tabela 14. Powtórzenie na 4 podziałach (2026–2029) × 5 seedów (42–46), 6 zbiorów zależnych od podziału, n = 20 par na zbiór. Bootstrap hierarchiczny losuje podziały, a w nich seedy (4 podziały to niewiele, więc CI są orientacyjne).

Zbiór	ewolucja	losowanie	różnica	95% CI (bootstrap po parach)	95% CI (hierarchiczny)	ocena praktyczna
Moons	0,9640	0,9637	0,0003	[−0,0015; 0,0020]	[−0,0026; 0,0029]	praktycznie zaniedbywalna
Circles	0,9806	0,9807	−0,0001	[−0,0008; 0,0007]	[−0,0011; 0,0012]	praktycznie zaniedbywalna
Spiral	0,9119	0,9134	−0,0015	[−0,0059; 0,0026]	[−0,0072; 0,0038]	nierozstrzygnięta
Classification 2D	0,9395	0,9387	0,0009	[−0,0018; 0,0037]	[−0,0019; 0,0043]	praktycznie zaniedbywalna
Digits	0,9612	0,9581	0,0031	[−0,0007; 0,0073]	[−0,0016; 0,0087]	nierozstrzygnięta
MAGIC	0,8322	0,8342	−0,0020	[−0,0052; 0,0013]	[−0,0054; 0,0013]	nierozstrzygnięta



Rys. 4. Różnice ewolucja − losowanie (harmonogram identyczny) w punktach procentowych, z 95% CI. Szare pasmo = ±0,5 p.p.

Nie wykazano praktycznie istotnej przewagi ewolucyjnego doboru V′ nad doborem losowym. Różnice BA na teście wynoszą od −0,21 do +0,31 p.p., żadna nie przekracza przyjętej granicy 0,5 p.p. CI wyklucza zero tylko na Szachownicy (+0,31 p.p., CI [0,0013; 0,0050], p Holma 0,045, d_z = 0,74); ta różnica jest mała, niespójna między metrykami (F1-macro: p Holma 0,095; BA pełne V: 0,066) i nie powtarza się na innym zbiorze, a Szachownica nie ma podziałów dodatkowych. Górna granica CI jest poniżej 0,5 p.p. na 6 z 7 zbiorów (Szachownica, Moons, Circles, Spiral, Classification 2D, MAGIC), więc na nich można wykluczyć przewagę ewolucji ≥ 0,5 p.p. (na Szachownicy brzegowo: górna granica CI = 0,0050); nie można tego zrobić dla Digits (szerokie CI). Na MAGIC ewolucja ma nominalnie niższe F1-macro (−0,0045, CI [−0,0078; −0,0013], p Holma 0,264) — bez potwierdzenia po korekcie. Na podziałach dodatkowych żadne CI (także hierarchiczne) nie wyklucza zera.

Porównanie pomocnicze z rand_switch (samodzielny automat losowy, mniejsze V′ i K): ewolucja ma wyższe BA na teście na 7 z 7 zbiorów, a CI wyklucza zero na Szachownicy, Moons, Spiral. Ta różnica miesza efekt doboru z efektem mniejszego |V′| i K u wariantu losowego, więc nie jest dowodem przewagi ewolucji (rand_switch kończy się wcześniej, najczęściej po braku postępu po próbie V′).

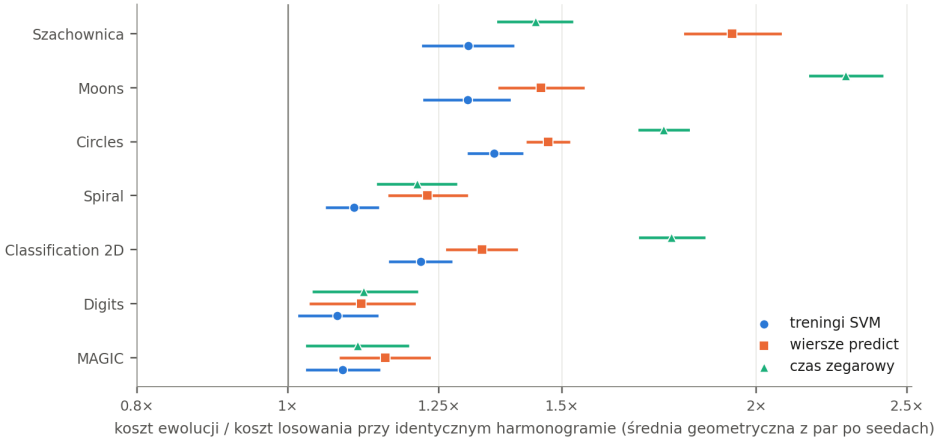
5.5 Czy ewolucja jest warta dodatkowego kosztu? (P3)

Tabela 15. Koszt całego przebiegu (średnia na przebieg, podział 2026, n = 20): wywołania modelu wykonane przez algorytm (bez obserwacji pełnego V i testu). Koszt T′ = oceny GA × |V′|; koszt V′ = ocena puli kandydatów (ewolucja: jedno predict na pulę) + diagnostyka ΔV′. Treningi SVM = oceny osobników T′ + 1 trening końcowy na krok T′.

Zbiór	Wariant	treningi SVM	oceny osobników T′	oceny osobników Val-GA	wywołania predict	wiersze predict	decision function	wiersze ΔV′	wiersze V′ w T′
Szachownica	ewolucja	6 577	6 544	15 057	6 652	2 219 303	24	478	1 549 530
	los. (harm. ewol.)	5 093	5 061	0	5 141	1 192 855	24	478	1 183 950
	los. (własny)	5 159	5 130	0	5 204	1 214 710	21	423	1 205 160
Moons	ewolucja	3 623	3 603	10 742	3 678	826 506	17	341	742 260
	los. (harm. ewol.)	2 806	2 786	0	2 840	579 278	17	341	574 500
	los. (własny)	2 179	2 164	0	2 207	447 185	13	259	443 250
Circles	ewolucja	5 610	5 578	17 262	5 698	1 783 805	27	548	1 647 810
	los. (harm. ewol.)	4 149	4 118	0	4 204	1 221 790	27	548	1 211 400
	los. (własny)	2 525	2 508	0	2 556	549 227	15	294	544 470
Spiral	ewolucja	6 972	6 936	13 072	7 039	1 592 874	21	415	1 488 030
	los. (harm. ewol.)	6 365	6 328	0	6 406	1 332 794	21	415	1 323 900
	los. (własny)	5 043	5 014	0	5 085	1 034 305	19	387	1 026 270
Classification 2D	ewolucja	5 151	5 122	13 986	5 222	1 372 016	22	444	1 261 560
	los. (harm. ewol.)	4 239	4 210	0	4 283	1 043 812	22	444	1 035 900
	los. (własny)	3 483	3 460	0	3 525	812 602	19	380	805 380
Digits	ewolucja	1 254	1 246	1 260	1 260	143 792	2	120	141 525
	los. (harm. ewol.)	1 158	1 150	0	1 162	125 789	2	120	124 845
	los. (własny)	1 118	1 112	0	1 123	119 578	2	120	118 575
MAGIC	ewolucja	4 847	4 827	11 718	4 906	879 303	19	372	818 700
	los. (harm. ewol.)	4 476	4 456	0	4 514	764 876	19	372	760 860
	los. (własny)	4 485	4 466	0	4 518	683 924	15	295	679 770

Tabela 16. Stosunek kosztu ewolucji do kosztu losowania przy identycznym harmonogramie (średnia geometryczna z 20 par po seedach, 95% CI z bootstrapu logarytmu). Czas zegarowy pochodzi z równoległych uruchomień na jednej maszynie (ok. 10–12 procesów) — miara pomocnicza.

Zbiór	treningi SVM	wiersze predict (łącznie)	wiersze predict w fazie V′	czas zegarowy
Szachownica	1,31 [1,22; 1,39]	1,93 [1,80; 2,08]	691×	1,44 [1,37; 1,52]
Moons	1,30 [1,22; 1,39]	1,45 [1,37; 1,55]	116×	2,28 [2,17; 2,41]
Circles	1,36 [1,31; 1,41]	1,47 [1,43; 1,51]	114×	1,74 [1,68; 1,81]
Spiral	1,10 [1,06; 1,14]	1,23 [1,16; 1,30]	116×	1,21 [1,14; 1,28]
Classification 2D	1,22 [1,16; 1,27]	1,33 [1,27; 1,40]	115×	1,76 [1,68; 1,85]
Digits	1,08 [1,02; 1,14]	1,12 [1,03; 1,20]	6×	1,12 [1,04; 1,21]
MAGIC	1,08 [1,03; 1,14]	1,16 [1,08; 1,23]	76×	1,11 [1,03; 1,19]



odcinek = 95% CI (bootstrap z logarytmu stosunku, 20 par na zbiór, podział 2026). Czas zegarowy pochodzi z równoległych uruchomień na jednej maszynie — miara pomocnicza.

Rys. 5. Stosunek kosztu ewolucji do kosztu losowania (harmonogram identyczny), skala logarytmiczna, z 95% CI.

Koszt ewolucji jest wyższy, i to nie tylko przez Val-GA. Przy identycznym harmonogramie ewolucja wymaga 1,08–1,36× treningów SVM (dolna granica CI na wszystkich zbiorach > 1: 1,02) i 1,12–1,93× wierszy predict. Większość kosztu to faza T′ (GA dla T′ ocenia kilka tysięcy osobników). Na tych samych krokach harmonogramu (3 516 par, podział 2026) GA dla T′ trwa w wariancie ewolucyjnym średnio o 1,09 generacji dłużej (dłużej w 42% par, krócej w 20%), a tylko 3,4% uruchomień kończy się osiągnięciem BA(V′) = 1 wobec 8,1% w losowaniu (średnie BA(V′) kroku T′: 0,908 wobec 0,961). Dane są zgodne z wyjaśnieniem, że trudniejsze V′ zostawia GA więcej miejsca na poprawę i wczesne zatrzymanie następuje rzadziej; związku przyczynowego nie testowano. Sam Val-GA dodaje w fazie V′ ocenę całej puli kandydatów (np. Szachownica ≈ 660 tys. wierszy na przebieg wobec ≈ 1 tys. dla losowania); decision_function jest wywoływane tylko diagnostycznie (jedno wywołanie na krok V′). Czas zegarowy: 1,11–2,28× (ograniczenie: równoległe uruchomienia, więc nie jest podstawą wniosku).

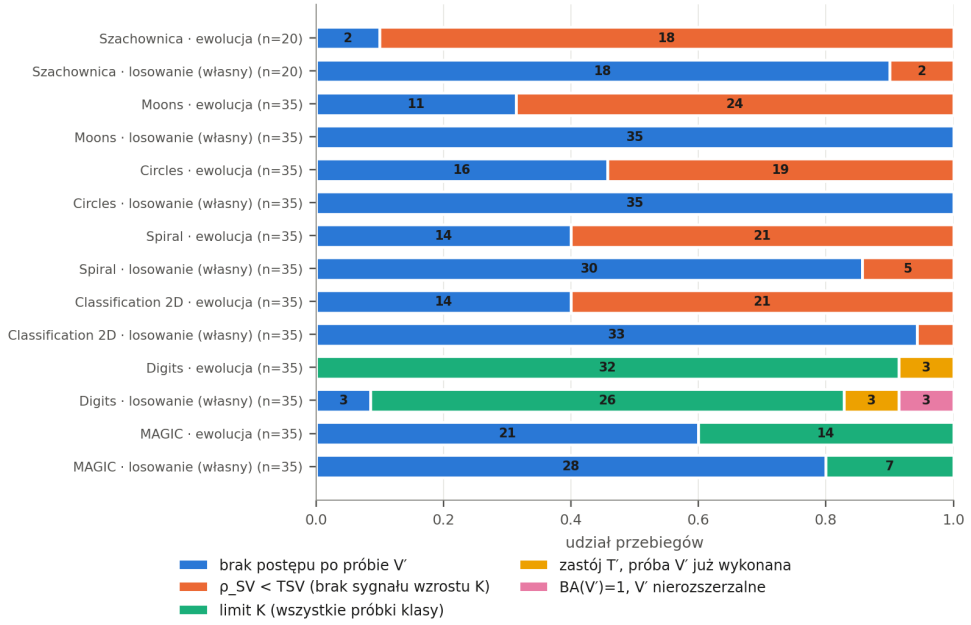
Czy warto? Przy kosztach wyższych o 8–36% (treningi SVM) i 12–93% (wiersze predict) ewolucja nie dała praktycznie istotnej poprawy jakości (sekcja 5.4). Na danych tego badania koszt dodatkowy nie jest uzasadniony zyskiem jakościowym. Zastrzeżenie: wniosek dotyczy zakresu rozmiarów V′ z tego badania; nie sprawdzano mniejszych V′ ani innych metryk fitness.

5.6 Pilotaż (oznaczony jako pilotażowy, poza wnioskami)

Tabela 17. Pilotaż (2–3 seedy na komórkę; chess_r1000: limit |V′| = 1000, bramka ρ_{SV} włączona; chess_r1000_nogate: limit 1000, bramka wyłączona). Wyłącznie ilustracja wykonalności porównania przy |V′| ≈ 1000.

Seria	Zbiór	Wariant	n	|V′| śr. (min–max)	|V′|/|V|	K końc.	BA test	cykle
chess_r1000	Szachownica	ewolucja	2	520 (320–720)	0,019	892	0,9745	56,5
chess_r1000	Szachownica	los. (harm. ewol.)	2	520 (320–720)	0,019	892	0,9687	56,5
chess_r1000	Szachownica	los. (własny)	2	440 (380–500)	0,016	817	0,9650	49,5
chess_r1000_nogate	Szachownica	ewolucja	2	870 (740–1 000)	0,031	5 530	0,9868	102,0
chess_r1000_nogate	Szachownica	los. (harm. ewol.)	2	870 (740–1 000)	0,031	5 530	0,9867	102,0
chess_r1000_nogate	Szachownica	los. (własny)	2	440 (380–500)	0,016	818	0,9650	51,0
moons	Moons	ewolucja	3	440 (300–540)	0,092	87	0,9688	41,7
moons	Moons	los. (harm. ewol.)	3	440 (300–540)	0,092	87	0,9671	41,7
moons	Moons	los. (własny)	3	247 (140–320)	0,051	72	0,9640	27,3

6. Analiza warunku stopu



liczby w segmentach = liczba przebiegów (segmenty < 7,5% bez liczby). Wszystkie serie główne (podziały 2026–2029). rand_replay kończy się z konstrukcji razem z przebiegiem ewolucyjnym.

Rys. 6. Powody zakończenia przebiegów (wszystkie serie główne; Szachownica tylko podział 2026). rand_replay kończy się z konstrukcji razem z przebiegiem ewolucyjnym.

Tabela 18. Powody zakończenia (liczba przebiegów; serie główne). Żaden przebieg nie zakończył się bezpiecznikiem max_cycles.

Zbiór	Wariant	n	brak postępu po próbie V′	ρ_{SV} < TSV	limit K	zastój T′ (próba wykonana)	BA=1, V′ nierozsz.
Szachownica	ewolucja	20	2	18	0	0	0
	los. (własny)	20	18	2	0	0	0
Moons	ewolucja	35	11	24	0	0	0
	los. (własny)	35	35	0	0	0	0
Circles	ewolucja	35	16	19	0	0	0
	los. (własny)	35	35	0	0	0	0
Spiral	ewolucja	35	14	21	0	0	0
	los. (własny)	35	30	5	0	0	0
Classification 2D	ewolucja	35	14	21	0	0	0
	los. (własny)	35	33	2	0	0	0
Digits	ewolucja	35	0	0	32	3	0
	los. (własny)	35	3	0	26	3	3
MAGIC	ewolucja	35	21	0	14	0	0
	los. (własny)	35	28	0	7	0	0

Warunek braku postępu jest aktywny i skuteczny. Wśród 230 przebiegów ewolucyjnych 78 (34%) kończy się brakiem postępu po próbie V′, a 103 (45%) — bramką ρ_{SV}; w losowaniu z własnym automatem 182 z 230 (79%) kończy się brakiem postępu. Przebiegi ewolucyjne kończą się więc najczęściej, gdy ρ_{SV} spada poniżej TSV (K jest wtedy wystarczająco duże), a losowe — gdy po próbie V′ T′ nie poprawia się, co następuje wcześniej i przy mniejszym V′ i K. Prób V′ po zastoju (przejście T′→V′ bez BA(V′) = 1): 1450; w 1190 (82%) T′ osiągnęło poziom odniesienia — w 1068 z nich (90%) już w pierwszym kroku po powrocie z V′ (dzięki warm startowi), w pozostałych po kolejnych zwiększeniach K; 260 (18%) zakończyło przebieg (stop po braku postępu, gdy K nie mogło rosnąć albo 3 zwiększenia nie dały poziomu). Zabezpieczenia przed zapętleniem nie musiały działać: 0 przebiegów z max_cycles, 0 powtórzonych prób na poziom K.

7. Analiza warunku przełączania faz

Tabela 19. Przełączenia faz na przebieg (średnie; serie główne, wszystkie podziały: Szachownica n = 20, pozostałe n = 35). rand_replay pominięto, bo jego przejścia są narzucone harmonogramem ewolucji. W ostatniej fazie T′ przebiegu T′→V′ nie następuje, dlatego liczba powrotów V′→T′ jest równa liczbie wejść do V′.

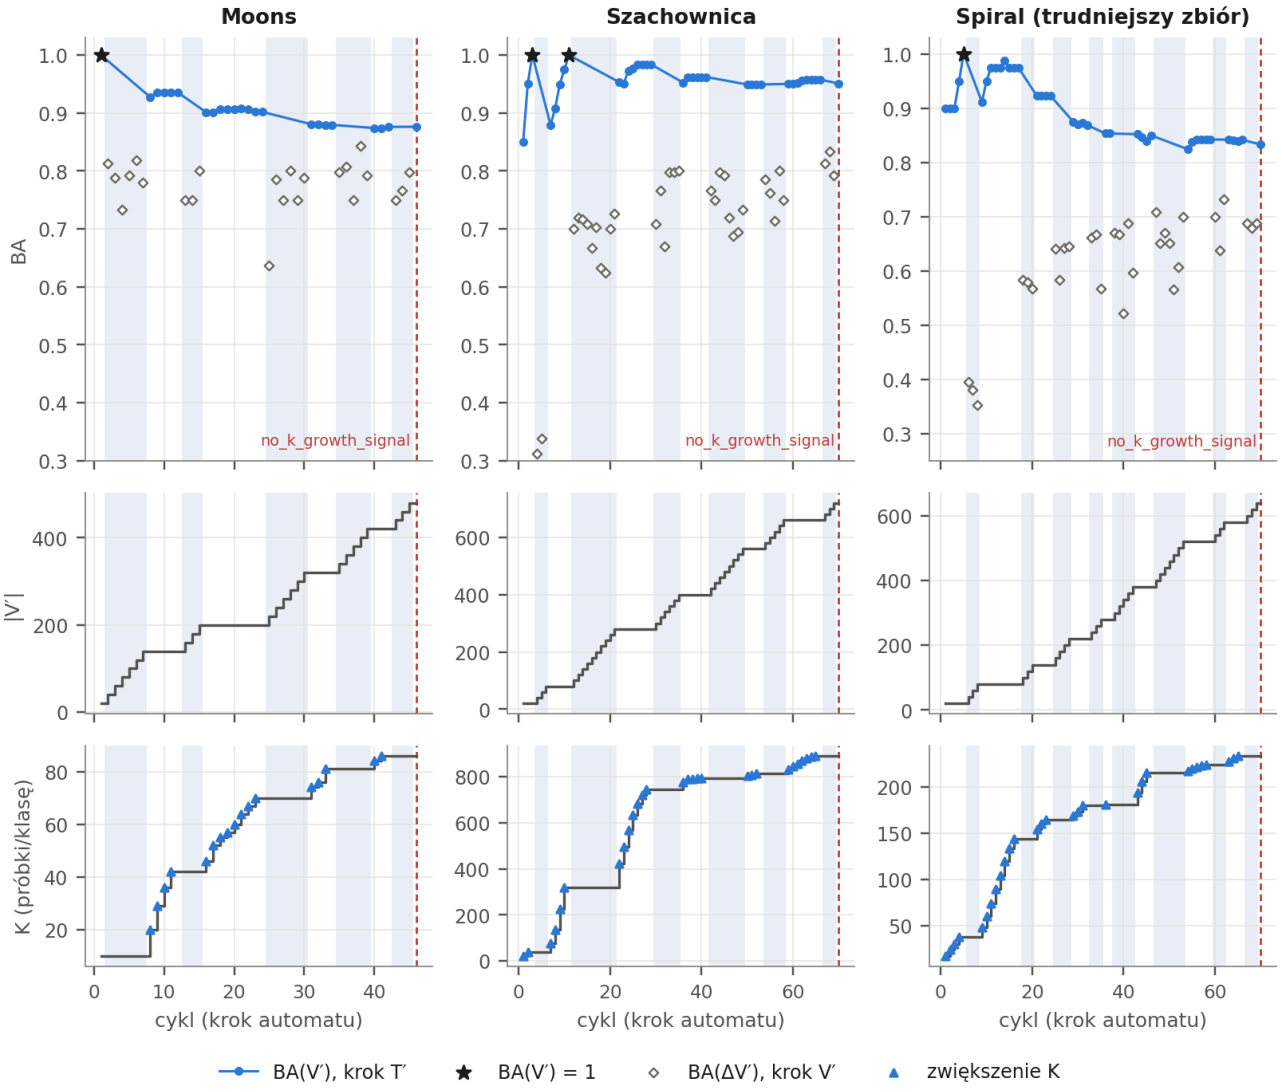
Zbiór	Wariant	n	T′→V′	w tym BA(V′)=1	w tym zastój/ρ_{SV}	V′→T′	wzrosty K	rozszerzenia V′	kroki T′ z BA=1
Szachownica	ewolucja	20	5,5	1,8	3,8	5,5	25,5	23,9	1,8
	los. (własny)	20	5,7	2,9	2,8	5,7	22,4	21,1	2,9
Moons	ewolucja	35	4,5	1,0	3,5	4,5	14,7	17,3	1,0
	los. (własny)	35	3,6	1,6	2,0	3,6	10,4	12,8	1,6
Circles	ewolucja	35	7,1	1,0	6,2	7,1	26,0	28,9	1,0
	los. (własny)	35	3,8	1,7	2,1	3,8	12,0	13,4	1,7
Spiral	ewolucja	35	5,3	0,7	4,6	5,3	28,3	21,0	0,7
	los. (własny)	35	4,5	0,7	3,7	4,5	22,6	20,0	0,7
Classification 2D	ewolucja	35	5,7	0,7	5,0	5,7	22,0	23,2	0,7
	los. (własny)	35	4,1	0,7	3,5	4,1	16,1	17,5	0,7
Digits	ewolucja	35	1,0	0,6	0,4	1,0	5,0	2,0	0,6
	los. (własny)	35	1,0	0,6	0,4	1,0	4,8	2,0	0,7
MAGIC	ewolucja	35	3,7	0,4	3,4	3,7	15,4	17,8	0,4
	los. (własny)	35	3,3	0,4	2,9	3,3	15,6	14,5	0,4

Przejścia. W przebiegu ewolucyjnym (poza Digits) T′→V′ następuje średnio 3,7–7,1 razy na przebieg, V′→T′ tyle samo, K wzrasta 15–28 razy, V′ jest rozszerzane 17–29 razy; na Digits (limit rozmiaru, limit K klasy) jest jedno przejście, 5 wzrostów K i 2 rozszerzenia. Z 1069 wejść do fazy V′ w wariancie ewolucyjnym **186 (17%)** pochodzi z BA(V′) = 1, a 883 z zastoju T′ lub bramki ρ_{SV}. BA(V′) = 1 występuje w 90% przypadków na V′ startowym (mediana |V′| przy BA = 1: 20 próbek; nie zawsze w cyklu 1 — T′ potrzebuje czasem kilku cykli, żeby opanować nawet 20 próbek).

Tabela 20. Co dzieje się po osiągnięciu BA(V′) = 1 (wszystkie kroki T′ z BA = 1 w seriach głównych, warianty z własnym automatem). Po BA = 1 algorytm zawsze przechodzi do fazy V′ (wyjątek: 3 stopy przy nierozszerzalnym V′, Digits).

Wariant	kroków T′ z BA=1	stop zamiast V′	długość fazy V′ (rozszerzenia)	błąd na ΔV′ w tej fazie	następny krok T′: BA(V′)	następny krok T′ znów BA=1
ewolucja	186	0	3,96	0,343	0,910	1 z 186 (0,5%)
los. (własny)	257	3	3,90	0,110	0,955	42 z 257 (16,3%)

Co dzieje się po BA(V′) = 1. Następuje faza V′ (średnio ok. 4 rozszerzenia po 20 próbek). W wariancie ewolucyjnym przyrosty są bardzo trudne (błąd modelu na ΔV′ ≈ 0,34), więc po powrocie do T′ BA(V′) spada (średnio do 0,91), a ponowne BA = 1 zdarza się w 1 z 186 przypadków; w losowaniu przyrosty są łatwe (błąd ≈ 0,11) i BA = 1 wraca w 16% przypadków. Z tego powodu po początkowym opanowaniu V′ ścieżka „BA = 1 → V′" prawie się nie powtarza w wariancie ewolucyjnym, a dalsze wejścia do fazy V′ wynikają z zastoju T′.



Jasne tło = faza optimize_V_prime; czerwona linia = stop (powód przy linii). Podział 2026, seed 42, wariant ewolucyjny.

Rys. 7. Trajektorie faz dla trzech zbiorów (podział 2026, seed 42, wariant ewolucyjny): BA(V′) w krokach T′ i BA(ΔV′) w krokach V′ (góra), |V′| (środek), K ze zaznaczonymi zwiększeniami (dół). Jasne tło = faza optimize_V_prime; czerwona linia = stop.

Trajektorie mają wspólny wzór: krótki początkowy etap, w którym T′ opanowuje małe V′ (gwiazdki), pierwsza faza V′, a następnie „piłokształtny" przebieg — seria zwiększeń K w fazie T′ bez zmiany V′, zastój, jedna próba V′ (jasne tło, 3–6 rozszerzeń), ponowne zwiększenia K. BA(V′) maleje wraz z utrudnianiem V′ (ewolucja dobiera próbki, na których model się myli), a BA(ΔV′) pozostaje niskie przez cały przebieg. Przebiegi kończą się przy ρ_{SV} < TSV (Moons, Szachownica, Spiral w tych przykładach).

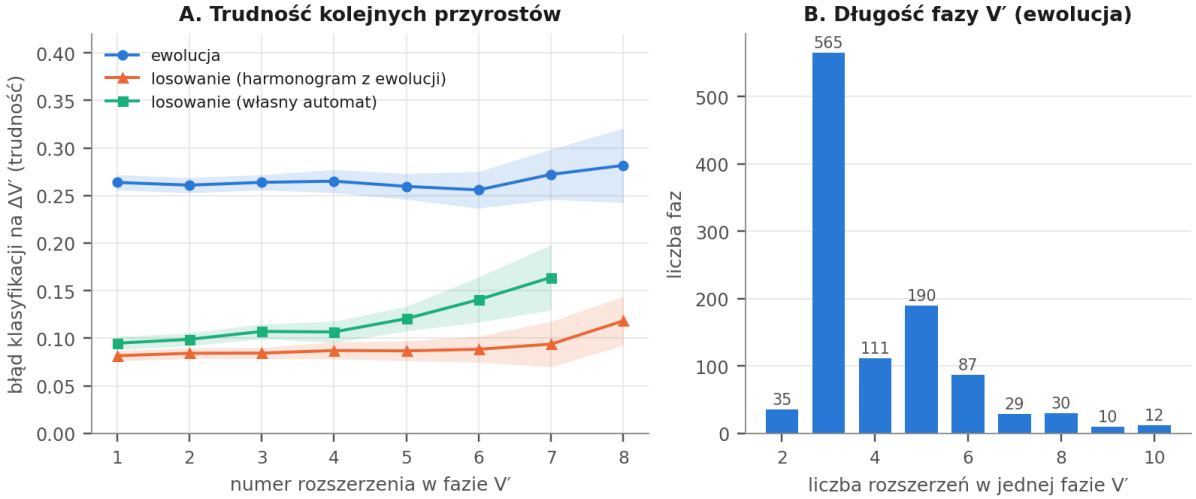
7.1 Przyczyny wejścia do fazy V′ bez BA(V′) = 1 i zasada „najpierw K”

Tabela 21. Powody wejścia do fazy V′ przy BA(V′) < 1 (warianty z własnym automatem, serie główne).

Zbiór	zastój: 3 zwiększenia K bez poprawy	bramka ρ_{SV} < TSV (bez zwiększenia K)	limit K klasy (bez zwiększenia K)
Szachownica	117	14	0
Moons	177	17	0
Circles	260	30	0
Spiral	237	54	0
Classification 2D	268	29	0
Digits	22	0	6
MAGIC	186	0	33
Razem	**1267**	**144**	**39**

Z 9620 kroków T′ z BA(V′) < 1 7713 (80,2%) zwiększa K — zasada „najpierw K” obowiązuje w zdecydowanej większości. Odstępstwem są 144 wejść do V′ z powodu bramki ρ_{SV} (K nie zwiększono) i 39 z powodu limitu K klasy (K nie mogło rosnąć) — łącznie 1,9% kroków z BA < 1. Pozostałe 1267 wejść poprzedziły 3 nieskuteczne zwiększenia K, zgodnie z założeniem.

7.2 Warunek końca fazy V′: czy jakość nowych próbek przestaje się pogarszać?



Rys. 8. A: błąd klasyfikacji na ΔV′ w zależności od numeru rozszerzenia w fazie V′ (średnia i 95% CI; serie główne, punkty o n ≥ 50). B: rozkład liczby rozszerzeń w jednej fazie V′ (ewolucja).

Trudność ΔV′ **nie rośnie** wraz z kolejnymi rozszerzeniami fazy: w wariancie ewolucyjnym błąd na ΔV′ jest praktycznie stały (≈ 0,26 dla numerów rozszerzenia 1–6), a zmiana między ostatnim a pierwszym przyrostem fazy wynosi średnio −0,019. Warunek „trudność przestała rosnąć o ≥ 0,01 przez 2 przyrosty” jest więc spełniany niemal natychmiast: 96% faz kończy się plateau trudności, a 53% faz trwa dokładnie 3 rozszerzenia (minimum przy cierpliwości 2). Średnia długość fazy to 4,1 rozszerzenia (mediana 3). Jakość klasyfikacji nowych próbek faktycznie „przestaje się pogarszać”, ale dzieje się to od pierwszego przyrostu, więc reguła działa głównie jak stała liczba rozszerzeń na fazę (parametr vprime_difficulty_patience), a nie jak adaptacyjny sygnał. W losowaniu trudność lekko rośnie z numerem rozszerzenia (0,10 → 0,14 dla numerów 1–6), co przedłuża część faz.

8. Ograniczenia i problemy

8.1 Różnice względem założeń

- **Zasada „najpierw K” spełniona częściowo.** Bramka ρ_{SV} (K rośnie tylko przy ρ_{SV} ≥ TSV) powoduje przejście do V′ bez zwiększenia K w 144 przypadkach; po nieudanej próbie V′ ta sama bramka kończy algorytm, bo K nie może rosnąć. Bramka dziedziczona jest z polityki DAGA; jej zmiana wymaga przeprojektowania wzoru na K_{next} (wartość bezwzględna).
- **BA(V′) = 1 może zakończyć algorytm**, ale tylko gdy V′ nie da się rozszerzyć (3 przypadki, Digits, limit rozmiaru).

- **Poziom odniesienia po próbie V′** to najlepszy T′ sprzed próby oceniony na tym samym, rozszerzonym V′ (+ 0,0005), a nie dosłownie jego fitness sprzed próby: V′ po próbie jest trudniejsze, więc dosłowne porównanie kończyłoby algorytm prawie zawsze. Wariant dosłowny jest zaimplementowany (retry_reference: literal), ale nie był uruchamiany.
- **Ocena puli kandydatów.** Val-GA ocenia osobniki na podzbiorach ΔV′, ale predykcje dla całej puli V \ V′ są liczone raz na rozszerzenie (zbuforowane); na Szachownicy (pula ≈ 27 tys.) to droższe niż nominalna ocena podzbiorów. Stare próbki V′ nie są oceniane ponownie.
- **rand_replay jest uprzywilejowany**: jego harmonogram (K, liczba cykli, moment stopu) pochodzi z ewolucji; rand_switch jest samodzielny, ale ma mniejsze V′ i K. Wariant rand_fixed (rozmiar z wyniku ewolucji) nie był używany.

8.2 Ograniczenia metodologiczne

- **Liczba podziałów i seedów.** Podział bazowy: 20 seedów; trzy podziały dodatkowe: tylko 5 seedów; Szachownica ma jeden podział. Różnice rzędu 0,1–0,3 p.p. leżą poniżej rozdzielczości układu; CI hierarchiczne (4 podziały) są orientacyjne.
- **Porównania wielokrotne.** Wartości p są korygowane metodą Holma tylko w obrębie 7 zbiorów dla danej metryki; CI nie są korygowane; metryk jest kilka, więc pojedyncze wyniki istotne należy czytać ostrożnie.
- **Granica praktycznej istotności 0,5 p.p.** jest przyjętą konwencją, nie wynikiem z danych.
- **Brak niezależności metryk.** BA na teście, F1-macro i BA na pełnym V pochodzą z tego samego modelu reprezentatywnego i są silnie skorelowane; nie stanowią niezależnych potwierdzeń. Obserwacje z jednego podziału nie są w pełni niezależne.
- **Porównanie ze starym algorytmem jest opisowe**: różni się nie tylko rozmiarem V′, ale też polityką K, przełączaniem faz i warm startem T′.
- **Metryki.** Fitness = BA; F1 i AUC nie były używane jako fitness, AUC nie został policzony; porównanie metryk pozostaje do wykonania. Pełne V jest tylko obserwacją (tak działa implementacja).
- **Hiperparametry.** (C, γ) wspólne dla podziałów; parametry automatu nie były strojone; wrażliwość nie była badana. Stała pula obserwacji: zmienność wynikająca z generowania danych nie jest uwzględniona.
- **Koszt.** Liczniki obejmują predict i decision_function; przy probability = true predict_proba nie byłoby liczone (wszystkie serie mają probability = false). Czas zegarowy pochodzi z równoległych uruchomień.

9. Wnioski

9.1 Potwierdzone przez dane

Tabela 22. Wnioski potwierdzone (status wyliczony z danych; „potwierdzone” = spełnione w badanych zbiorach i podziałach, nie więcej).

Twierdzenie	Podstawa w danych
Automat dwóch faz działa zgodnie z założeniami: BA(V′) = 1 przełącza do V′ (nie kończy algorytmu), po V′ następuje T′, K rośnie najwyżej raz na cykl, T′ widzi cały skumulowany V′, pełne V i test nie sterują.	wymagania 1–5 i 7–11 spełnione (z zastrzeżeniami z sekcji 5.1) na 690 przebiegach i 27 671 cyklach (0 naruszeń); 0 przebiegów z max_cycles
V′ nie rośnie do nadmiernych rozmiarów: Szachownica 498 wobec 3 528 (stary algorytm).	20 par seedów; maks. |V′|/|V| = 0,236; maks. |V′| na Szachownicy 800
BA na teście nowego algorytmu nie jest gorsze od starego o więcej niż 0,5 p.p. na 6 z 7 zbiorów (Szachownica, Moons, Circles, Spiral, Classification 2D, MAGIC): przy 4–7× mniejszym V′ na Szachownicy, MAGIC i Digits (Digits: patrz 9.2), przy podobnym lub większym V′ na pozostałych.	dolna granica 95% CI różnicy sparowanej (nowy − stary) > −0,005 (porównanie opisowe)
Ewolucja wybiera istotnie trudniejsze próbki do ΔV′ niż losowanie.	7/7 zbiorów: CI wyklucza zero, p Holma < 0,001, d_z ≥ 3,6
Ewolucja kosztuje więcej niż losowanie przy tym samym harmonogramie.	treningi SVM 1,08–1,36×, wiersze predict 1,12–1,93×; dolna granica CI treningów > 1 na wszystkich zbiorach
Nie wykazano praktycznie istotnej (≥ 0,5 p.p.) przewagi ewolucji nad losowaniem w BA na teście; na 6 zbiorach (Szachownica, Moons, Circles, Spiral, Classification 2D, MAGIC) można ją wykluczyć.	górna granica 95% CI różnicy ewolucja − losowanie (rand_replay) < 0,005

9.2 Sugerowane przez dane

Tabela 23. Obserwacje sugerowane (widoczne w danych, bez wystarczającego potwierdzenia).

Obserwacja	Dlaczego tylko sugerowana
Na Szachownicy ewolucja ma wyższe BA na teście (+0,31 p.p.).	p Holma 0,045 dla BA, ale 0,095 dla F1-macro; poniżej 0,5 p.p.; brak replikacji (jeden podział)
Na MAGIC ewolucja ma nominalnie niższe F1-macro niż losowanie.	CI wyklucza zero, ale p Holma 0,264; BA na teście bez różnicy
Na Szachownicy większe V′ wiąże się z wyższym BA w obrębie nowego algorytmu (ρ cząstkowa po kontroli K = 0,51).	n = 20, bez korekty na wielokrotność, zależność nieprzyczynowa (długość przebiegu); brak na pozostałych zbiorach
rand_switch (samodzielny automat losowy) ma niższe BA niż ewolucja; CI wyklucza zero na: Szachownica, Moons, Spiral.	różnica zmieszana z mniejszym |V′| i K u wariantu losowego
Przy 4× mniejszym V′ na Digits nie można wykluczyć spadku jakości > 0,5 p.p.	różnica −0,0043, CI [−0,0100; 0,0004]

9.3 Nie rozstrzygnięte

- Czy ewolucyjny dobór V′ pomaga przy znacznie mniejszych V′ niż w tym badaniu (nie badano stałej siatki rozmiarów V′).
- Wpływ bramki ρ_{SV} na jakość: sprawdzony tylko w pilotażu na Szachownicy (n = 2) — bez bramki K rośnie do ≈ 5500, a BA test jest wyższe, kosztem kilkukrotnie większego czasu.
- Porównanie BA z F1 i AUC jako fitnessem (AUC nie został policzony; wymaga probability = true i rozszerzenia Val-GA).
- Czy próg „opanowania” poniżej 1,0 zmieniłby rolę ścieżki „BA = 1 → V′”, która dziś dotyczy głównie V′ startowego.
- Wrażliwość wyników na parametry automatu (przyrost ΔV′, progi trudności, liczba zastojów) i na wybór modelu reprezentatywnego.
- Czy wyniki utrzymują się na większej liczbie podziałów i seedów oraz dla zbiorów o większej liczbie klas niż Digits.

10. Proponowane dalsze kroki

- Zdecydować z promotorem o roli bramki ρ_{SV} (zachować, czy zmienić wzór na K_{next} i pozwolić K rosnąć przy $\rho_{SV} <$ TSV) — to najsilniej wpływa na zakończenie przebiegów i jakość na Szachownicy.
- Zbadać stałą siatkę rozmiarów V′ (np. 100, 200, 500, 1000) dla ewolucji i losowania przy tym samym K, żeby odpowiedzieć, czy ewolucja pomaga przy małych V′.
- Przeanalizować próg opanowania poniżej 1,0 oraz stałą/adaptacyjną liczbę rozszerzeń w fazie V′ (dziś de facto 3).
- Porównać BA, F1 i AUC jako fitness (probability = true, definicja progu opanowania dla AUC).
- Rozważyć „leniwe” predykcje w Val-GA (tylko wiersze użyte przez osobniki), żeby obniżyć koszt oceny puli kandydatów.
- Zwiększyć liczbę seedów na podziałach dodatkowych oraz zbadać wrażliwość na parametry automatu.

11. Instrukcja odtworzenia eksperymentu

Wszystkie polecenia uruchamiane są w katalogu głównym repozytorium (środowisko .venv). Kolejka wznawia przerwane przebiegi (pomija ukończone). Każdy seed to osobna flaga --seeds. Poprzednie wyniki (v1, followup_stop_rule) i stary tryb dagasvm_phase pozostają niezmienione.

```
./.venv/bin/pytest -q                                  # 140 testow

# podzial bazowy 2026, 7 zbiorow, seedy 42-61 (420 przebiegow)
./.venv/bin/python scripts/followup_phase_switch/run_queue.py --series v2_full \
    -d chessboard -d spiral -d magic -d circles -d classification2d -d digits -d moons \
    -v evo_switch -v rand_switch -v rand_replay --seeds 42 --seeds 43 ... --seeds 61 -w 10

# podzialy dodatkowe (po 90 przebiegow: 6 zbiorow, seedy 42-46)
./.venv/bin/python scripts/followup_phase_switch/run_queue.py --series v2_split2027 --split 2027 \
    -d spiral -d magic -d circles -d classification2d -d digits -d moons \
    -v evo_switch -v rand_switch -v rand_replay --seeds 42 --seeds 43 --seeds 44 --seeds 45 --seeds 46 -w 4
./.venv/bin/python scripts/followup_phase_switch/aggregate.py --version v2
./.venv/bin/python scripts/followup_phase_switch/final_report.py     # tabele, wykresy, PDF i Markdown
```

Pliki wynikowe i ich lokalizacja w repozytorium (podziały 2028 i 2029 uruchamiane analogicznie do 2027, z opcjami --series i --split; pilotaż: serie v2_smoke_* z --set max_vprime_rows=1000, a dla wariantu bez bramki dodatkowo --set k_growth_requires_sv_signal=false).

```
output/pdf/raport_phase_switch.pdf                  # ten raport
reports/followup_phase_switch/RAPORT.md              # wersja Markdown
reports/followup_phase_switch/tables/final_*.csv     # tabele wynikowe
reports/followup_phase_switch/figures/               # wykresy
artifacts/followup_phase_switch/v2_*                 # przebiegi (summary.json, cycles.csv, konfiguracje)
```